

Microeconometria II

Clase 1B

Modelos Lineales

Edinson Tolentino

email: edinson.tolentino@gmail.com

Twitter: [@edutoleraymondi](https://twitter.com/edutoleraymondi)

Centro de Formación Continua

22 de noviembre de 2025



Microeconometria II

Temas

Sesión

Logro de la sesión

Predicción

Descomposición MSE

Aplicación

Selección de modelo


SESIONES	TÓPICOS	DESCRIPCION
Tema 1	MODELOS LINEALES Retornos a la educación Predicciones bajo modelos lineales	Teoría y Práctica
Tema 2	MODELOS DE SELECCIÓN Truncamiento Censura Modelos de Heckman	Teoría y Práctica
Tema 3	MODELOS DE DURACIÓN Conceptos estadísticos básicos Funcion de riesgos Determinantes de la reincidencia de crimen	Teoría y Práctica
Tema 4	MODELO DE CUANTILES Extension de regresion lineal Aplicacion de Oaxaca-Blinder Modelo de regresion por cuantiles	Teoría y Práctica
Tema 5	CALCULO DE PODER Conceptos básicos Estrategias para incrementar el poder estadistico Calculo de poder usando simulaciones	Teoría y Práctica

Cuadro: Topicos.



► Al término de la sesión el alumno(a) podrá conocer y realizar:

- ✓ Analisis de prediccion
- ✓ Selecccion de mejor modelo de prediccion
- ✓ Aplicacion de cross-validation





► **Contexto:**

- Datos originales (lo que tenemos) → para construir un modelo
- Datos en vivo (datos que aún no tenemos)
- Identificar nuestras variables de objetivo (Y) y sus posibles factores (X)

► **Cual es lo nuevo?**

- La mayor parte de la econometría se centra en la relación entre X y Y
- Usamos

$$\hat{y}_j = \hat{f}(x_j)$$

- ¿En qué se diferencia esto?
- Nos importa menos:
 1. Los valores individuales de los coeficientes, la multicolinealidad
 2. Aun así, nos importa la estabilidad de nuestros resultados.



- ▶ Prediccion de error , prediccion de valor $\hat{y}_j$
- ▶ Entonces:

$$e_j = \hat{y}_j - y_j$$

- ▶ El error de predicción ideal es cero: nuestro valor predicho coincide exactamente con el valor real.
- ▶ El error de predicción puede descomponerse en tres partes:
 1. Error de estimación: la diferencia entre el valor estimado por el modelo y el valor verdadero del modelo.
 2. Error del modelo: la diferencia entre el valor verdadero del modelo y el mejor valor predictor; es decir, puede que no tengamos el mejor modelo.
 3. Error genuino (idiosincrático o irreducible): error debido a la imposibilidad de estimar perfectamente todos los valores predichos, incluso si el error de estimación es cero y tenemos el mejor modelo posible.
- ▶ Por tanto, trabajaremos el error como una funcion de perdida:

$$e_j^2 = (\hat{y}_j - y_j)^2$$



- Debemos utilizar indicadores de prediccion, entre ellos :

Error cuadratico promedio
$$\text{MSE} = \frac{1}{K} \sum_{k=1}^K (\hat{y}_k - y_k)^2$$

Raiz Error cuadratico promedio
$$\text{RMSE} = \sqrt{\frac{1}{K} \sum_{k=1}^K (\hat{y}_k - y_k)^2}$$

- Donde k puede tomar valores de $1, 2, 3, \dots, K$ (observaciones)
- El MSE implica el valor medio para el mejor predictor
- Segun el metodo de OLS, el MSE brinda la solución al problema de minimización de mínimos cuadrados es el promedio.
- ¡El MSE es el numerador del R-cuadrado!



- ▶ Se puede descomponer el MSE en sesgo + varianza
 - 1. El sesgo de una predicción es el promedio de su error de predicción.
 - ▶ Una predicción insesgada produce un error promedio igual a cero a lo largo de múltiples predicciones.
 - ▶ Una predicción sesgada produce un error promedio distinto de cero; el sesgo puede ser positivo o negativo.
 - 2. La varianza de una predicción describe cómo varía alrededor de su valor promedio cuando se hacen múltiples predicciones.
 - ▶ Es la varianza del error de predicción alrededor de su valor promedio.
 - ▶ La varianza es cero si el error de predicción es el mismo en todas las predicciones.
 - ▶ La varianza es mayor cuanto más se dispersan las predicciones específicas alrededor de la predicción promedio

$$\begin{aligned} \text{MSE} &= \frac{1}{K} \sum_{k=1}^K (\hat{y}_k - y_k)^2 \\ &= \underbrace{\frac{1}{K} (\hat{y}_k - \bar{y})^2}_{\text{Sesgo}^2} + \underbrace{\frac{1}{K} (y_k - \bar{y})^2}_{\text{Prediccion de varianza}} \end{aligned}$$

- ▶ Supongamos que quieres vender tu coche de una determinada marca, tipo, año, kilometraje, condición y otras características.
- ▶ El análisis de predicción ayuda a descubrir el precio promedio de venta anunciado para autos con esas características.
- ▶ Eso te ayuda a decidir qué precio podrías poner en tu anuncio.





- Bajo las variables , se propone una serie de 5 modelos:

Modelos	Descripcion
price	Variable TARGET
Modelo 1	age, age al cuadrado
Modelo 2	age, age squared, odometer, odometer squared
Modelo 3	age, age squared, odometer, odometer squared, LE, condition like new, excellent condition, good condition, dealer
Modelo 4	age, age squared, odometer, odometer squared, LE, condition like new, excellent condition, good condition, dealer, SE, XLE, cylinder
Modelo 5	same as Modelo 4 but with all variables interacted with age

- **Odometer**, que mide las millas que ha recorrido el carro (en unidades de 10 mil millas), es probablemente un fuerte predictor del precio.
- **Tipos de autos**, LE, XLE, SE (esta información falta en aproximadamente el 30 por ciento de las observaciones).
- Se incluye además si el anuncio indica que el carro está en buen estado, excelente estado, o como nuevo (like new, excellent).
- Variable dummy de dealer , el vendedor.



- ▶ La función de pérdida para predecir el valor de nuestro coche usado depende de cómo valoramos el dinero y cómo valoramos el tiempo que tarda en venderse nuestro coche.
- ▶ Una predicción demasiado baja puede llevar a vender nuestro coche barato pero rápido
- ▶ Una predicción demasiado alta puede hacer que esperemos mucho tiempo y, posiblemente, tengamos que ajustar el precio de venta a la baja antes de vender el coche.
 - ▶ Simétrica
 - ▶ Sensible a grandes desviaciones
 - ▶ RMSE y OLS



- ▶ La selección de modelo consiste en encontrar el mejor ajuste evitando el sobreajuste y buscando una alta validez externa.
- ▶ Tenemos un conjunto de datos y una variable objetivo. Comparamos varios modelos de predicción.
- ▶ ¿Cómo elegir un modelo?
 - ▶ Mejor predicción: el mejor modelo que produciría el menor error de predicción.
 - ▶ En el contexto de la función de pérdida cuadrática → encontrar la regresión que produzca **el RMSE más pequeño** para las observaciones objetivo.
 - ▶ Escoge un modelo que pueda predecir bien en **los datos en vivo**.
- ▶ Comparando dos modelos (modelo 1 y modelo 2)
- ▶ El modelo 1 puede dar un peor ajuste en los datos en vivo que el modelo 2 de dos maneras.
- ▶ El modelo 1 puede dar un peor ajuste tanto en los datos originales como en los datos en vivo. En este caso, decimos que el modelo 1 subajusta los datos originales.
 - ▶ Simple: deberíamos construir un mejor modelo.




- ▶ Overfitting o sobreajuste es un aspecto clave de la validez externa
 - ▶ Encontrar un modelo que se ajuste mejor a los datos que otros modelos alternativos
 - ▶ Pero que haga peores predicciones reales.
- ▶ Por lo tanto, el problema del sobreajuste de los datos originales se divide mejor en dos problemas
- ▶ Ajustar patrones en los datos originales que no existen en la población, o patrón general, que representan
- ▶ Ajustar patrones en el mundo de los datos originales que no estarán presentes en el mundo de los datos en vivo.
- ▶ La razón típica del sobreajuste es ajustar un modelo que es demasiado complejo para el conjunto de datos.
 - ▶ Complejidad: número de coeficientes estimados
- ▶ A menudo: ajustar un modelo con demasiadas variables predictoras.
 - ▶ Incluir demasiadas variables del conjunto de datos que en realidad no aportan al poder predictivo de la regresión

Selección de modelo: overfitting



- ▶ A medida que aumentamos la complejidad del modelo
- ▶ Como el número de características (variables)
- ▶ Veremos que
 1. El RMSE dentro del conjunto de datos caerá de manera monótona
 2. El RMSE para las observaciones objetivo (es decir, que no están en nuestro conjunto de datos) caerá y luego aumentará a medida que sobreajustemos.



Selección modelo: pasos



- ▶ Muestra: entrenamiento (80 %) y test (20 %), de forma aleatoria
- ▶ Dividir la muestra $k = 5$ veces para entrenar y probar
- ▶ Para cada pliegue:
 - ▶ Estimar el modelo en el conjunto de entrenamiento.
 - ▶ Obtener los coeficientes.
 - ▶ Usarlos para estimar en el conjunto de prueba.
- ▶ Calcular el MSE de prueba.
- ▶ Promediar y sacar la raíz cuadrada.
- ▶ Repetir para los modelos.
- ▶ Escoger el modelo con el RMSE promedio más bajo.

