

Microeconometria II

Práctica 4A

Modelos de Cuantiles

Edinson Tolentino

email: edinson.tolentino@gmail.com

Twitter: @edutoleraymondi

Centro de Formación Continua

30 de noviembre de 2025



Introducción

Logro de la sesión

Preguntas

Pregunta 1

Pregunta 2

Pregunta 3

Pregunta 4



Ronald Oaxaca
(1943 – present)
University of Arizona



Alan Blinder
(1945 – present)
Princeton University



Ronald Oaxaca
(1943 – present)
University of Arizona

Alan Blinder
(1945 – present)
Princeton University

- ▶ Ambos desarrollaron un número índice de descomposición usado para determinar el total de la diferencia en promedio del logaritmo de salarios entre dos grupos (por ejemplo: raza, genero, etc)



Ronald Oaxaca
(1943 – present)
University of Arizona



Alan Blinder
(1945 – present)
Princeton University

- ▶ Ambos desarrollaron un número índice de descomposición usado para determinar el total de la diferencia en promedio del logaritmo de salarios entre dos grupos (por ejemplo: raza, genero, etc)
- ▶ El mismo puede ser dividido en dos componentes, **explicado** y **no explicado**



Ronald Oaxaca
(1943 – present)
University of Arizona

Alan Blinder
(1945 – present)
Princeton University

- ▶ Ambos desarrollaron un número índice de descomposición usado para determinar el total de la diferencia en promedio del logaritmo de salarios entre dos grupos (por ejemplo: raza, genero, etc)
- ▶ El mismo puede ser dividido en dos componentes, **explicado** y **no explicado**
- ▶ El componente **no explicado** es generalmente interpretado como la **discriminación** de salario en el mercado laboral



Ronald Oaxaca
(1943 – present)
University of Arizona



Alan Blinder
(1945 – present)
Princeton University

- ▶ Ambos desarrollaron un número índice de descomposición usado para determinar el total de la diferencia en promedio del logaritmo de salarios entre dos grupos (por ejemplo: raza, genero, etc)
- ▶ El mismo puede ser dividido en dos componentes, **explicado** y **no explicado**
- ▶ El componente **no explicado** es generalmente interpretado como la **discriminación** de salario en el mercado laboral
- ▶ La metodología llegó a ser conocido como descomposición **Oaxaca-Blinder(OB)**



- ✓ Comprender los conceptos básicos de la decomposicion de Oaxaca-Blinder (OB) y su relación con la literatura sobre efectos de tratamientos.
- ✓ Comprender como se implementa la decomposicion de OB en softwares, interpretar los resultados.
- ✓ Comprender como implementar la decomposicion de OB incondicional a la regresion por cuantiles basado en la función de influencia recentrada (RIF's)

Pregunta 1



- ▶ Resume los datos en bruto. En particular, ¿qué variables difieren estadísticamente entre los dos grupos de género?



Variables	Descripción
log wage	Salario mensual del trabajador
educ	años de educacion
exper	años de experiencia
expersq	años de experiencia al cuadrado
tenure	número de años trabajando en el actual trabajo
single	== 1, si el individuo es soltero
married	== 1, si el individuo es casado
female	== 1, si el individuo es mujer
male	== 1, si el individuo es hombre


Cuadro: Statistics

	Trabajadores	Promedio	Mediana	Min.	Max.	Std
log hourly wages	1434	3.36	3.40	0.51	5.26	1
years of education	1434	11.54	10.50	5.00	17.50	2
years of work experience	1434	13.15	10.92	0.00	49.17	10
expersq	1434	272.29	119.17	0.00	2,417.36	366
years of job tenure	1434	7.86	5.29	0.00	44.83	8
married	1434	0.47	0.00	0.00	1.00	0
divorced	1434	0.14	0.00	0.00	1.00	0
single	1434	0.39	0.00	0.00	1.00	0
male	1434	0.52	1.00	0.00	1.00	0

Fuente: BD4.


Elaboracion: Author

Figura 1: Distribución Acumulada de salarios según tipo de trabajo



Fuente : Data
Elaboración: Autor

Figura 2: Distribución de salarios según tipo de genero



Cuadro: test de media segun genero

	Diferencias por genero		
	Mujer	Hombre	Δ
log hourly wages	3.27 (0.57)	3.44 (0.48)	0.17***
years of education	11.23 (2.35)	11.81 (2.45)	0.58***
years of work experience	12.14 (8.33)	14.08 (11.18)	1.94***
expersq	216.55 (274.87)	322.99 (426.28)	106.43***
years of job tenure	6.61 (6.73)	9.00 (9.06)	2.40***
married	0.41 (0.49)	0.52 (0.50)	0.11***
divorced	0.20 (0.40)	0.09 (0.28)	-0.11***
single	0.39 (0.49)	0.39 (0.49)	0.00
male	0.00 (0.00)	1.00 (0.00)	1.00
Observations	683	751	1434

Note: Grupos de control y tratamiento en relacion al genero

Standard deviations in parentheses.

***, **, * denote statistical significance at the 1%, 5% and 10% levels respectively for zero.

Fuente: BD4.

Elaboration: Author



- Estime las ecuaciones de salarios por un modelo de MCO separada por cada grupo (mujer vs hombre)

$$\log \text{wage}_i = \alpha_0 + \alpha_1 \text{educ}_i + \alpha_2 \text{exper} + \alpha_3 \text{expersq} + \alpha_4 \text{tenure} \\ + \alpha_5 \text{married} + \alpha_6 \text{divorce} + \varepsilon$$

Implemente la descomposición de Oaxaca-Blinder (OB) asumiendo que, en ausencia de trato desigual, prevalece la estructura salarial masculina. ¿Qué concluye sobre la magnitud del efecto de “trato” y del efecto de “dotaciones”? Compare esto con el caso en el que, en ausencia de trato desigual, prevalece la estructura salarial femenina. ¿Qué observa?

Pregunta 2



- La estrategia de estimación : se procede a estimar la siguiente ecuación lineal de ingresos dado el método de OLS (MCO) separadamente entre hombres y mujeres

$$\log \text{wage}_i = \alpha_0 + \alpha_1 \text{educ}_i + \alpha_2 \text{exper} + \alpha_3 \text{expersq} + \alpha_4 \text{tenure} + \alpha_5 \text{married} + \alpha_6 \text{divorce} + \varepsilon_i$$

Cuadro: Log (Salarios) OLS por tipo

	Mujer	Hombre
years of education	0.09*** (0.01)	0.07*** (0.01)
years of work experience	0.05*** (0.01)	0.04*** (0.01)
expersq	-0.00*** (0.00)	-0.00*** (0.00)
years of job tenure	0.01* (0.00)	0.01*** (0.00)
married	-0.08** (0.04)	0.21*** (0.03)
divorced	0.17*** (0.05)	0.17*** (0.05)
Observaciones	683	751
Adj. R ²	0.202	0.402

Fuente: BD4.

Elaboración: Autor

Nota: Estimaciones robustas (MVC)



- ▶ La estimación de **OB** requiere las estimaciones por separado de los trabajadores independientes **mujeres (m)** y los **hombres (h)**

Mujer	$w_m = X_m\beta_m + \varepsilon_m$
Hombre	$w_h = X_h\beta_h + \varepsilon_h$

- ▶ Donde se asume que $E(\varepsilon_m, X_m) = E(\varepsilon_h, X_h) = 0$



- ▶ Como conocemos las propiedades de estimación de **MCO**, la cual regresiona o estima a través del promedio de las variables explicativas y explicada
- ▶ Entonces, usando dicha propiedad, se tiene

$$\bar{w}_m = \bar{X}_m' \hat{\beta}_m$$

$$\bar{w}_h = \bar{X}_h' \hat{\beta}_h$$

- ▶ Los valores de **color rojo**, estan denotados por como escalares (1×1)
 - ▶ De manera empirica se tiene un vector $\bar{X}_h$ de dimensión 7×1 para las características (controles) del trabajador independiente formal
 - ▶ Por otro lado, un vector $\hat{\beta}_h$ de dimensión 7×1 para las coeficientes (estimadores) segun el MCO
 - ▶ Entonces, $\bar{X}_h$ y $\hat{\beta}_h$ poseen las misma dimensión 7×1 para los trabajadores independiente informal

- ▶ La diferencia de genero en el promedio de logaritmo de ingresos esta dado por:

$$\Delta_0 = \bar{w}_h - \bar{w}_m$$

$$\Delta_0 = \bar{X}_h^T \hat{\beta}_h - \bar{X}_m^T \hat{\beta}_m$$

- ▶ Si se suma y resta la expresión $\bar{X}_m^T \hat{\beta}_m$
- ▶ Esto crea un contrafacutal que se relaciona con el problema de perdida de información, por tanto la ecuación quedará:

$$\Delta_0 = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_h + \bar{X}_m^T (\hat{\beta}_h - \hat{\beta}_m)$$

- ▶ Esto supone que prevalece una **estructura salarial trabajador hombre** en ausencia de un trato desigual.



- ▶ $\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_h$, denota efecto de dotación
- ▶ $\Delta_T = \bar{X}_m^T (\hat{\beta}_h - \hat{\beta}_m)$, denota efecto tratamiento
- ▶ Δ_T se interpreta como el efecto de tratamiento promedio (ATT) sobre los tratados
- ▶ En la literatura empírica usando dicha metodología , este ultimo termino es conocido como el efecto **discriminación**





- La diferencia de genero en el promedio de logaritmo de ingresos esta dado por:



- ▶ La diferencia de genero en el promedio de logaritmo de ingresos esta dado por:

$$\Delta_0 = \bar{w}_h - \bar{w}_m$$

$$\Delta_0 = \bar{X}_h^T \hat{\beta}_h - \bar{X}_m^T \hat{\beta}_m$$

- ▶ Si se suma y resta la expresión $\bar{X}_h^T \hat{\beta}_m$
- ▶ Esto crea un contrafacutal que se relaciona con el problema de perdida de información, por tanto la ecuación quedará:

$$\Delta_0 = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m + \bar{X}_h^T (\hat{\beta}_h - \hat{\beta}_m)$$

- ▶ Esto supone que prevalece una **estructura salarial trabajador mujer** en ausencia de un trato desigual.





- $\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$, denota efecto de dotación



- ▶ $\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$, denota efecto de dotación
- ▶ $\Delta_T = \bar{X}_h^T (\hat{\beta}_h - \hat{\beta}_m)$, denota efecto tratamiento



- ▶ $\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$, denota efecto de dotación
- ▶ $\Delta_T = \bar{X}_h^T (\hat{\beta}_h - \hat{\beta}_m)$, denota efecto tratamiento
- ▶ Δ_T se interpreta como el efecto de tratamiento promedio (ATT) sobre los tratados



- ▶ $\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$, denota efecto de dotación
- ▶ $\Delta_T = \bar{X}_h^T (\hat{\beta}_h - \hat{\beta}_m)$, denota efecto tratamiento
- ▶ Δ_T se interpreta como el efecto de tratamiento promedio (ATT) sobre los tratados
- ▶ En la literatura empírica usando dicha metodología , este ultimo termino es conocido como el efecto **discriminación**
- ▶ **Nota:** Estos dos enfoques pueden producir diferentes estimaciones del efecto de trato. Este fenómeno se conoce como el “problema del número índice”



- ▶ Entonces, ¿por qué se llama el “problema del número índice”?
- ▶ Recordemos, de la estadística básica, el cálculo de los índices de precios.
- ▶ Existen dos índices de precios comunes utilizados para calcular un índice de precios al consumidor:
 1. El índice de precios usando la fórmula de Laspeyres.
 - ▶ Este pondera los precios utilizando **las cantidades del año base como ponderadores**.
 2. El índice de precios usando la fórmula de Paasche.
 - ▶ Este pondera los precios utilizando las cantidades del año corriente como ponderadores.
- ▶ Las distintas fórmulas producen resultados diferentes; de ahí el “problema del número índice”.



- ▶ Fortin et al. (2010) sostienen que el supuesto de media condicional cero impuesto para los errores de la ecuación del log - salario en la descomposición OB no son necesario para estimar consistentemente el ATT, es decir:

$$E(\varepsilon_h|X_h) = E(\varepsilon_m|X_m)$$

- ▶ El supuesto de independencia en la media puede reemplazarse por un supuesto más débil de ignorabilidad.
- ▶ Los no observables no necesitan ser independientes de X , siempre y cuando su distribución condicional (dado X) sea la misma en ambos grupos de género.
- ▶ El tratamiento OB se presenta como un contrafactual simple (es decir, bajo el supuesto SUTVA, lo cual implica ausencia de spill-overs).
- ▶ Un supuesto de common support (o solapamiento) también está implícito en la descomposición OB (es decir, las variables determinantes del salario deben ser las mismas en ambas ecuaciones).
- ▶ Fortin et al. (2010) sostienen que, si se realiza un contrafactual simple y se cumplen los supuestos de ignorabilidad y common support, entonces los componentes agregados de OB (es decir, ΔE y ΔT) son identificables.



- Implemente la descomposición de Oaxaca-Blinder (OB) asumiendo que, en ausencia de trato desigual, **prevalece la estructura salarial masculina**. ¿Qué concluye sobre la magnitud del efecto de “trato” y del efecto de “dotaciones”? Compare esto con el caso en el que, en ausencia de trato desigual, prevalece la estructura salarial femenina. ¿Qué observa?

Prevalece la estructura salarial masculina



```
. oaxaca8 male female, weight(1)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222

Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=1						
explained	.0510809	.0185199	2.76	0.006	.0147825	.0873793
unexplained	.1223798	.0265121	4.62	0.000	.070417	.1743426

Prevalece la estructura salarial masculina



```
. oaxaca8 male female, weight(1)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222

Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=1						
explained	.0510809	.0185199	2.76	0.006	.0147825	.0873793
unexplained	.1223798	.0265121	4.62	0.000	.070417	.1743426

- Dado la que prevalece la estructura salarial masculina

Prevalece la estructura salarial masculina



```
. oaxaca8 male female, weight(1)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222

Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=1						
explained	.0510809	.0185199	2.76	0.006	.0147825	.0873793
unexplained	.1223798	.0265121	4.62	0.000	.070417	.1743426

- Dado la que prevalece la estructura salarial masculina

$$\Delta_0 = \bar{w}_h - \bar{w}_m = 0.1734$$

Prevalece la estructura salarial masculina



```
. oaxaca8 male female, weight(1)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222

Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	-.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=1						
explained	.0510809	.0185199	2.76	0.006	.0147825	.0873793
unexplained	.1223798	.0265121	4.62	0.000	.070417	.1743426

- Dado la que prevalece la estructura salarial masculina

$$\Delta_0 = \bar{w}_h - \bar{w}_m = 0.1734$$

- Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_h$$

$$\Delta_E = 0.05$$

Prevalece la estructura salarial masculina



```
. oaxaca8 male female, weight(1)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222

Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	0.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=1						
explained	.0510809	.0185199	2.76	0.006	.0147825	.0873793
unexplained	.1223798	.0265121	4.62	0.000	.070417	.1743426

- ▶ Dado la que prevalece la estructura salarial masculina

$$\Delta_0 = \bar{w}_h - \bar{w}_m = 0.1734$$

- ▶ Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_h$$


$$\Delta_E = 0.05$$

- ▶ Tratamiento (Discriminacion)


$$\Delta_T = \bar{X}_m^T (\hat{\beta}_h - \hat{\beta}_m)$$

$$\Delta_T = 0.1223$$

Prevalece la estructura salarial masculina




Prevalece la estructura salarial masculina



- Dado la que prevalece la estructura salarial masculina


Prevalece la estructura salarial masculina



- Dado la que prevalece la estructura salarial masculina

$$\Delta_0 = \bar{w}_h - \bar{w}_m = 0.1734$$

Prevalece la estructura salarial masculina



- ▶ Dado la que prevalece la estructura salarial masculina


$$\Delta_0 = \bar{w}_h - \bar{w}_m = 0.1734$$

- ▶ Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_h$$

$$\Delta_E = 0.05$$

Prevalece la estructura salarial masculina



- ▶ Dado la que prevalece la estructura salarial masculina

$$\Delta_0 = \bar{w}_h - \bar{w}_m = 0.1734$$

- ▶ Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_h$$

$$\Delta_E = 0.05$$

- ▶ Tratamiento (Discriminacion)

$$\Delta_T = \bar{X}_m^T (\hat{\beta}_h - \hat{\beta}_m)$$

$$\Delta_T = 0.1223$$

Prevalece la estructura salarial femenina



```
. oaxaca8 male female, weight(0)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222
Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=0						
explained	.0056583	.018401	0.31	0.758	-.030407	.0417236
unexplained	.1678024	.0264532	6.34	0.000	.1159552	.2196497

Prevalece la estructura salarial femenina



```
. oaxaca8 male female, weight(0)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222
Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=0						
explained	.0056583	.018401	0.31	0.758	-.030407	.0417236
unexplained	.1678024	.0264532	6.34	0.000	.1159552	.2196497

- Dado la que prevalece la estructura salarial femenina

Prevalece la estructura salarial femenina



```
. oaxaca8 male female, weight(0)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222
Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=0						
explained	.0056583	.018401	0.31	0.758	-.030407	.0417236
unexplained	.1678024	.0264532	6.34	0.000	.1159552	.2196497

- Dado la que prevalece la estructura salarial femenina

$$\Delta_0 = \bar{w}_m - \bar{w}_f = 0.1734$$

Prevalece la estructura salarial femenina



```
. oaxaca8 male female, weight(0)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222
Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=0						
explained	.0056583	.018401	0.31	0.758	-.030407	.0417236
unexplained	.1678024	.0264532	6.34	0.000	.1159552	.2196497

- Dado la que prevalece la estructura salarial femenina

$$\Delta_0 = \bar{w}_m - \bar{w}_f = 0.1734$$

- Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$$

$$\Delta_E = 0.005$$

Prevalece la estructura salarial femenina



```
. oaxaca8 male female, weight(0)  
(high estimates: male; low estimates: female)
```

Mean prediction 1 = 3.440222
Mean prediction 2 = 3.266761

	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
difference	.173460	.0281162	6.17	0.000	.1183541	.2285674

Linear decomposition

Total	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
W=0						
explained	.0056583	.018401	0.31	0.758	-.030407	.0417236
unexplained	.1678024	.0264532	6.34	0.000	.1159552	.2196497

- Dado la que prevalece la estructura salarial femenina

$$\Delta_0 = \bar{w}_m - \bar{w}_f = 0.1734$$

- Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$$


$$\Delta_E = 0.005$$

- Tratamiento (Discriminacion)


$$\Delta_T = \bar{X}_h^T (\hat{\beta}_h - \hat{\beta}_m)$$

$$\Delta_T = 0.16780$$

Prevalece la estructura salarial femenina




Prevalece la estructura salarial femenina



- Dado la que prevalece la estructura salarial femenina


Prevalece la estructura salarial femenina



- Dado la que prevalece la estructura salarial femenina

$$\Delta_0 = \bar{w}_m - \bar{w}_f = 0.1734$$

Prevalece la estructura salarial femenina



- ▶ Dado la que prevalece la estructura salarial femenina


$$\Delta_0 = \bar{w}_m - \bar{w}_f = 0.1734$$

- ▶ Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$$

$$\Delta_E = 0.005$$

Prevalece la estructura salarial femenina



- Dado la que prevalece la estructura salarial femenina

$$\Delta_0 = \bar{w}_m - \bar{w}_f = 0.1734$$

- Dotacion (endowment)

$$\Delta_E = (\bar{X}_h - \bar{X}_m)^T \hat{\beta}_m$$

$$\Delta_E = 0.005$$

- Tratamiento (Discriminacion)

$$\Delta_T = \bar{X}_h^T (\hat{\beta}_h - \hat{\beta}_m)$$

$$\Delta_T = 0.16780$$



- ▶ Si asumimos que prevalece una estructura salarial masculina en ausencia de trato desigual, el diferencial por trato se estima en 0.1224.
- ▶ Esto representa aproximadamente el 70 % del diferencial salarial total por género en esta aplicación.
- ▶ Alternativamente, si asumimos que prevalece una estructura salarial femenina en ausencia de trato desigual, ¡la historia cambia!
- ▶ El diferencial por trato ahora se estima en 0.1678 (es decir, casi toda la brecha salarial observada entre géneros).
- ▶ Este hallazgo refleja el “problema del número índice”, donde las estimaciones de las descomposiciones son sensibles a las canastas específicas de género de las características determinantes del salario.

Cuadro: Descomposicion
Oaxaca-Blinder

Descomposicion	
Brecha	0.173*** (0.028)
Explicada	0.051** (0.018)
No-explicada	0.122*** (0.026)
Observaciones	1434

Fuente: BD4.

***, **, * denote statistical significance
at the 1 %, 5 % and 10 % levels respectively
for zero.

Cuadro: Descomposicion
Oaxaca-Blinder

Descomposicion	
Brecha	0.173*** (0.028)
Explicada	0.051** (0.018)
No-explicada	0.122*** (0.026)
Observaciones	1434

Fuente: BD4.

***, **, * denote statistical significance
at the 1 %, 5 % and 10 % levels respectively
for zero.

Cuadro: Descomposicion
Oaxaca-Blinder

	Descomposicion
Brecha	0.173*** (0.028)
Explicada	0.051** (0.018)
No-explicada	0.122*** (0.026)
Observaciones	1434

Fuente: BD4.

***, **, * denote statistical significance
at the 1 %, 5 % and 10 % levels respec-
tively for zero.

- Entonces , asumiendo una estructura
prevalencia de salario de hombres, la brecha
de salarios es de 0.1734

Cuadro: Descomposicion
Oaxaca-Blinder

	Descomposicion
Brecha	0.173*** (0.028)
Explicada	0.051** (0.018)
No-explicada	0.122*** (0.026)
Observaciones	1434

Fuente: BD4.

***, **, * denote statistical significance at the 1 %, 5 % and 10 % levels respectively for zero.

- ▶ Entonces , asumiendo una estructura prevalencia de salario de hombres, la brecha de salarios es de 0.1734
- ▶ Se observa que el **efecto de discriminación (brecha no explicada)** entre los salarios de trabajadores formales e informales es de $\Delta_T = 0.1224$, la cual representa un 70 %.

Pregunta 3



- Calcule las brechas salariales incondicionales por género en los percentiles 10, 25, 50, 75 y 90. ¿Qué concluye sobre el patrón de estos diferenciales?

Modelo de Regresión cuántilica condicional





- El OLS provee estimaciones para el efecto promedio de algunas variables (por ejemplo, educación o género) sobre una variable de respuesta (por ejemplo, logaritmo de salario) esperando que otros factores se mantengan constante.



- ▶ El OLS provee estimaciones para el efecto promedio de algunas variables (por ejemplo, educación o género) sobre una variable de respuesta (por ejemplo, logaritmo de salario) esperando que otros factores se mantengan constante.
- ▶ Independientemente de dónde se encuentre en la distribución del logaritmo de salario, se supone que el efecto del género o la educación sobre el salario logarítmico es el mismo.



- ▶ El OLS provee estimaciones para el efecto promedio de algunas variables (por ejemplo, educación o género) sobre una variable de respuesta (por ejemplo, logaritmo de salario) esperando que otros factores se mantengan constante.
- ▶ Independientemente de dónde se encuentre en la distribución del logaritmo de salario, se supone que el efecto del género o la educación sobre el salario logarítmico es el mismo.
- ▶ La regresión por cuantiles relaja el supuesto de homogeneidad en la distribución condicional de la variable de resultado o respuesta.

Modelo de Regresión cuántilica condicional





- ▶ Si el individuo se encuentra en el percentil 10 de la distribución del logaritmo de salarios (por ejemplo, $\tau = 0.1$), 90 % de los individuos en la distribución tienen un logaritmo de salarios altos.



- ▶ Si el individuo se encuentra en el percentil 10 de la distribución del logaritmo de salarios (por ejemplo, $\tau = 0.1$), 90 % de los individuos en la distribución tienen un logaritmo de salarios altos.
- ▶ Si el individuo se encuentra a la mediana (por ejemplo, $\tau = 0.5$), 50 % de los individuos en la distribución tiene un logaritmo de salarios.



- ▶ Si el individuo se encuentra en el percentil 10 de la distribución del logaritmo de salarios (por ejemplo, $\tau = 0.1$), 90 % de los individuos en la distribución tienen un logaritmo de salarios altos.
- ▶ Si el individuo se encuentra a la mediana (por ejemplo, $\tau = 0.5$), 50 % de los individuos en la distribución tiene un logaritmo de salarios.
- ▶ Si el individuo se encuentra en el percentil 90 de la distribución del logaritmo de salarios (por ejemplo, $\tau = 0.9$), 10 % de los individuos en la distribución tienen un logaritmo de salarios altos.



- ▶ Si el individuo se encuentra en el percentil 10 de la distribución del logaritmo de salarios (por ejemplo, $\tau = 0.1$), 90 % de los individuos en la distribución tienen un logaritmo de salarios altos.
- ▶ Si el individuo se encuentra a la mediana (por ejemplo, $\tau = 0.5$), 50 % de los individuos en la distribución tiene un logaritmo de salarios.
- ▶ Si el individuo se encuentra en el percentil 90 de la distribución del logaritmo de salarios (por ejemplo, $\tau = 0.9$), 10 % de los individuos en la distribución tienen un logaritmo de salarios altos.
- ▶ Koenker y Basset extiende estos conceptos para el marco teórico de la regresión en la que las funciones cuantílicas condicionales pueden ser estimable.

Modelo de Regresión cuántilica condicional



Modelo de Regresión cuántilica condicional



- ▶ Según el OLS, se busca un vector β para minimizar la siguiente cantidad:



- Según el OLS, se busca un vector β para minimizar la siguiente cantidad:

$$SSE = \sum_{i=1}^n \left[w_i - x_i' \beta \right]^2$$



- Según el OLS, se busca un vector β para minimizar la siguiente cantidad:

$$SSE = \sum_{i=1}^n \left[w_i - x_i' \beta \right]^2$$

- En contraste para el OLS, la regresión cuantílica minimiza la suma ponderada de los errores absolutos, y no la suma de los errores cuadrados.



- ▶ Según el OLS, se busca un vector β para minimizar la siguiente cantidad:

$$SSE = \sum_{i=1}^n [w_i - x_i' \beta]^2$$

- ▶ En contraste para el OLS, la regresión cuantilica minimiza la suma ponderada de los errores absolutos, y no la suma de los errores cuadrados.
- ▶ Especialmente, para la regresión cuantilica del vector $\beta(\tau)$ es elegida para minimizar lo siguiente:



- Según el OLS, se busca un vector β para minimizar la siguiente cantidad:

$$SSE = \sum_{i=1}^n \left[w_i - x_i' \beta \right]^2$$

- En contraste para el OLS, la regresión cuantilica minimiza la suma ponderada de los errores absolutos, y no la suma de los errores cuadrados.
- Especialmente, para la regresión cuantilica del vector $\beta(\tau)$ es elegida para minimizar lo siguiente:

$$ASE = \sum_{i=1}^n \left[w_i - X_i' \beta(\tau) \right] \left[\tau \times I(w_i > X_i' \beta(\tau)) + (1 - \tau) \times I(w_i \leq X_i' \beta(\tau)) \right]$$



- Según el OLS, se busca un vector β para minimizar la siguiente cantidad:

$$SSE = \sum_{i=1}^n \left[w_i - x_i' \beta \right]^2$$

- En contraste para el OLS, la regresión cuantilica minimiza la suma ponderada de los errores absolutos, y no la suma de los errores cuadrados.
- Especialmente, para la regresión cuantilica del vector $\beta(\tau)$ es elegida para minimizar lo siguiente:

$$ASE = \sum_{i=1}^n \left[w_i - X_i' \beta(\tau) \right] \left[\tau \times I(w_i > X_i' \beta(\tau)) + (1 - \tau) \times I(w_i \leq X_i' \beta(\tau)) \right]$$

- Un caso especial de la función es la función condicional en la mediana , donde $\tau = 0.5$ y la expresión anterior colapsa como:

$$ASE = \sum_{i=1}^n \left[w_i - X_i' \beta(\tau) \right]$$



- ▶ Según el OLS, se busca un vector β para minimizar la siguiente cantidad:

$$SSE = \sum_{i=1}^n \left[w_i - x_i' \beta \right]^2$$

- ▶ En contraste para el OLS, la regresión cuantilica minimiza la suma ponderada de los errores absolutos, y no la suma de los errores cuadrados.
- ▶ Especialmente, para la regresión cuantilica del vector $\beta(\tau)$ es elegida para minimizar lo siguiente:

$$ASE = \sum_{i=1}^n \left[w_i - X_i' \beta(\tau) \right] \left[\tau \times I(w_i > X_i' \beta(\tau)) + (1 - \tau) \times I(w_i \leq X_i' \beta(\tau)) \right]$$

- ▶ Un caso especial de la función es la función condicional en la mediana , donde $\tau = 0.5$ y la expresión anterior colapsa como:

$$ASE = \sum_{i=1}^n \left[w_i - X_i' \beta(\tau) \right]$$

- ▶ Esta expresión es la regresión cuantilica condicional en la mediana conocida como the least absolute deviations (LAD) estimator

Modelo de Regresión cuántilica condicional





- ▶ A diferencia de MCO, la regresión de la mediana es menos sensible a los valores atípicos.



- ▶ A diferencia de MCO, la regresión de la mediana es menos sensible a los valores atípicos.
- ▶ Se ha vuelto cada vez más popular explorar regresiones cuantílicas distintas a la mediana.



- ▶ A diferencia de MCO, la regresión de la mediana es menos sensible a los valores atípicos.
- ▶ Se ha vuelto cada vez más popular explorar regresiones cuantílicas distintas a la mediana.
- ▶ Esto se puede hacer minimizando la suma de los residuos absolutos ponderados asimétricamente.



- ▶ A diferencia de MCO, la regresión de la mediana es menos sensible a los valores atípicos.
- ▶ Se ha vuelto cada vez más popular explorar regresiones cuantílicas distintas a la mediana.
- ▶ Esto se puede hacer minimizando la suma de los residuos absolutos ponderados asimétricamente.
- ▶ Por tanto, esto permite estimar la regresión de cuantiles en varios percentiles de los residuos (por ejemplo, 10^{th} , 25^{th} , 75^{th} o 90^{th}).



- ▶ A diferencia de MCO, la regresión de la mediana es menos sensible a los valores atípicos.
- ▶ Se ha vuelto cada vez más popular explorar regresiones cuantílicas distintas a la mediana.
- ▶ Esto se puede hacer minimizando la suma de los residuos absolutos ponderados asimétricamente.
- ▶ Por tanto, esto permite estimar la regresión de cuantiles en varios percentiles de los residuos (por ejemplo, 10^{th} , 25^{th} , 75^{th} o 90^{th}).
- ▶ Nosotros podemos entonces estimar $\beta(\tau)$ para cualquier τ entre los valores 0 y 1.

Cuadro: Estimacion del Log (Salarios) por regresion cuantilica condicional y OLS

	OLS	10 th Percentile	25 th Percentile	50 th Percentile	75 th Percentile	90 th Percentile
female	-0.1358*** (0.0247)	-0.2734*** (0.0546)	-0.1847*** (0.0333)	-0.1018*** (0.0198)	-0.0954*** (0.0214)	-0.0458 (0.0444)
Constant	2.0349*** (0.0829)	1.0852*** (0.1125)	2.0393*** (0.1003)	2.2178*** (0.0614)	2.5238*** (0.0790)	2.6411*** (0.1219)
Observaciones	1434	1434	1434	1434	1434	1434
Adj. R ²	0.292	0.273	0.280	0.287	0.286	0.266

Error estandar en parentesis

Fuente: BD4.

Nota: ***, **, * denota las significancia estadísticas al 0.01, 0.05 y 0.10

Los errores estandar (parentensis) son corregidos a traves del comando robust , usando el comando qreg2 (Machado y Santos-Silva(2013))

Elaboracion: Autor



- Implemente el procedimiento RIF basado en OLS para descomponer los percentiles 10, 25, 50, 75 y 90 de la distribución del log - salario en sus partes de “trato” (treatment) y “dotaciones” (endowment) usando la descomposición de Oaxaca - Blinder. ¿Qué concluye sobre la magnitud de los efectos de “trato” y “dotaciones” en estos percentiles? ¿Cómo comparan con las estimaciones OB de la media (pregunta 2)?




- ▶ Muchas estadísticas descriptivas comunes pueden expresarse mediante funcionales estadísticos.
- ▶ Un funcional estadístico es cualquier función de la función de distribución de la variable dependiente (es decir, y) definida como $F()$ y usualmente expresada como $T(F)$.

Promedio	$T(F) = \int y \partial F(y)$
----------	-------------------------------

Varianza	$T(F) = \int (y - \mu)^2 \partial F(y)$
----------	---


Cuantiles	$T(F) = \int F^{-1} \partial F(y)$
-----------	------------------------------------

The Cumulative Distribution Function (CDF) of $F(\cdot)$



Note: The derivative of the CDF $F(\cdot)$ is the pdf (i.e., $f(\cdot)$)

The Inverse Cumulative Distribution Function (ICDF) of $F(\cdot)$



Note: The derivative of the inverse CDF $F^{-1}(\cdot)$ is the reciprocal of the pdf (i.e., $1/f(\cdot)$)



- ▶ Suponiendo que el funcional estadístico es continuamente diferenciable, su derivada direccional de primer orden en F se conoce como la **función de influencia (IF)**.
- ▶ La IF representa la influencia de un dato individual (contaminado), es decir, de una observación, sobre la estadística distributiva de interés.
- ▶ Por ejemplo, la función de influencia (IF) de la media poblacional μ (es decir, $E(Y)$) es el valor de la variable dependiente centrado en la media, es decir, $IF_{\mu} = Y - \mu$.
- ▶ La IF aquí está centrada alrededor de 0.
- ▶ Si a la Distribución estadística de interés se le suma la IF, se obtiene lo que se conoce como la **función de influencia recentrada (RIF)**.



- ▶ Supongamos que $IF(y; \nu)$ es la función de influencia correspondiente a una variable observada y y que la estadística distributiva se define como $\nu(F_y)$.
- ▶ La **RIF** correspondiente a este caso se define como $RIF(y; \nu)$ donde:

$$RIF(y; \nu) = \nu(F_y) + IF(y; \nu)$$

- ▶ **Nota:** El promedio de la RIF es la estadística muestral de interés.



- La función de influencia (IF) para el valor del cuantíl q_τ de una variable aleatoria y (por ejemplo, los log-salarios) se da por:

$$\text{IF}(y; q_\tau) = \frac{\tau - I(y \leq q_\tau)}{f_Y(q_\tau)}$$



- La función de influencia (IF) para el valor del cuantíl q_τ de una variable aleatoria y (por ejemplo, los log-salarios) se da por:

$$\text{IF}(y; q_\tau) = \frac{\tau - I(y \leq q_\tau)}{f_Y(q_\tau)}$$

- Donde:



- ▶ La función de influencia (IF) para el valor del cuantíl q_τ de una variable aleatoria y (por ejemplo, los log-salarios) se da por:

$$IF(y; q_\tau) = \frac{\tau - I(y \leq q_\tau)}{f_Y(q_\tau)}$$

- ▶ Donde:
 - ▶ τ = el cuantíl de interés (por ejemplo, el percentil 10, donde $\tau = 0.1$);



- La función de influencia (IF) para el valor del cuantíl q_τ de una variable aleatoria y (por ejemplo, los log-salarios) se da por:

$$IF(y; q_\tau) = \frac{\tau - I(y \leq q_\tau)}{f_Y(q_\tau)}$$

- Donde:
 - τ = el cuantíl de interés (por ejemplo, el percentil 10, donde $\tau = 0.1$);
 - $I(\cdot)$ = un indicador que toma el valor 1 si la expresión entre paréntesis se cumple, y 0 en caso contrario;

- La función de influencia (IF) para el valor del cuantíl q_τ de una variable aleatoria y (por ejemplo, los log-salarios) se da por:

$$IF(y; q_\tau) = \frac{\tau - I(y \leq q_\tau)}{f_Y(q_\tau)}$$

- Donde:
 - τ = el cuantíl de interés (por ejemplo, el percentil 10, donde $\tau = 0.1$);
 - $I(\cdot)$ = un indicador que toma el valor 1 si la expresión entre paréntesis se cumple, y 0 en caso contrario;
 - $f_Y(q_\tau)$ = el valor de la densidad de probabilidad correspondiente al cuantíl q_τ .
- **NOTA:** La IF en el caso de los cuantiles es una variable dicotómica que solo puede tomar uno de dos valores:
 - $\frac{\tau-1}{f_Y(q_\tau)}$ cuando la variable aleatoria es menor o igual al cuantíl q_τ . También se puede expresar a veces como $\frac{-(1-\tau)}{f_Y(q_\tau)}$.
 - $\frac{\tau}{f_Y(q_\tau)}$ en los demás casos.



- Pasamos de la función de influencia (IF) a la función de influencia recentrada (RIF) sumando de nuevo la muestral relevante del cuantíl (q_τ):

$$\begin{aligned} \text{RIF}(y; q_\tau) &= q_\tau + \frac{\tau - I(y \leq q_\tau)}{f_Y(q_\tau)} \\ &= q_\tau + \frac{\tau - (1 - I(y > q_\tau))}{f_Y(q_\tau)} \\ &= q_\tau + \frac{I(y > q_\tau) + \tau - 1}{f_Y(q_\tau)} \\ &= q_\tau + \frac{I(y > q_\tau)}{f_Y(q_\tau)} - \frac{1 - \tau}{f_Y(q_\tau)} \end{aligned}$$

- **NOTA:** La RIF también es una variable dicotómica que solo puede tomar uno de dos valores:
 - $q_\tau + \frac{\tau-1}{f_Y(q_\tau)}$ cuando la variable aleatoria es menor o igual al cuantíl q_τ . A veces se puede reexpresar como $q_\tau - \frac{1-\tau}{f_Y(q_\tau)}$.
 - $q_\tau + \frac{\tau}{f_Y(q_\tau)}$ en los demás casos.



- Volviendo a la expresión de la RIF:

$$\text{RIF}(y; q_\tau) = q_\tau + \frac{I(y > q_\tau)}{f_Y(q_\tau)} - \frac{1 - \tau}{f_Y(q_\tau)}$$

- Esto se puede simplificar y reescribir como:

$$\text{RIF}(y; q_\tau) = c_{1,\tau} I(y > q_\tau) + c_{2,\tau}$$

- Donde:

$$c_{1,\tau} = \frac{1}{f_Y(q_\tau)},$$

$$c_{2,\tau} = q_\tau - c_{1,\tau}(1 - \tau)$$



- La RIF tiene varias propiedades interesantes, siendo la más importante que la media de la RIF es el cuantíl de interés (q_τ).

$$E[\text{RIF}(y; q_\tau) \mid X = x] = c_{1,\tau} E[I(y > q_\tau) \mid X = x] + c_{2,\tau}$$

$$E[\text{RIF}(y; q_\tau) \mid X = x] = c_{1,\tau} E[\text{Prob}(y > q_\tau) \mid X = x] + c_{2,\tau}$$

- La expectativa condicional $E[\text{RIF}(y; q_\tau) \mid X = x]$ es una función lineal de la probabilidad de que la variable aleatoria y esté por encima del cuantíl:

$$E[\text{Prob}(y > q_\tau) \mid X = x]$$

- ... lo cual a su vez es una función lineal de un conjunto de variables X .



- ▶ Por lo tanto, el modelo lineal RIF (cuantil) puede estimarse, en primera instancia, utilizando un simple **modelo lineal de probabilidad (LPM)**.

$$E[\text{RIF}(y; q_\tau) \mid X = x] = c_{1,\tau} E[\text{Prob}(y > q_\tau) \mid X = x] + c_{2,\tau}$$


- ▶ La relación anterior sugiere que un pequeño aumento en X tiene el mismo efecto sobre la probabilidad de que y esté por encima de q_τ que sobre el cuantil incondicional q_τ medido por la RIF
- ▶ exceptuando el factor de escala $c_{1,\tau} = \frac{1}{f_Y(q_\tau)}$.

PREGUNTA: ¿Qué papel cumple el factor de escala $\frac{1}{f_Y(q_\tau)}$ aquí?

- ▶ Sabemos que la función que transforma probabilidades en cuantiles incondicionales es el operador de la función de distribución acumulada inversa (ICDF).
- ▶ Y también sabemos que la pendiente de la función de distribución acumulada inversa es?
- ▶ el inverso de la densidad de probabilidad: $\frac{1}{f_Y(q_\tau)}$.



- ▶ El enfoque de regresión RIF-OLS implica la estimación de un **modelo lineal de probabilidad (LPM)** para determinar la probabilidad de que la variable esté por encima del cuantíl de interés (q_τ).
procedimiento de estimación produce **efectos marginales** (para las variables continuas) y **efectos de impacto** (para las variables ficticias o dummies) sobre las covariables X , los cuales se expresan en puntos de probabilidad.
- ▶ Bajo los supuestos estándar, se sabe que estas estimaciones LPM (OLS) son **consistentes**.
- ▶ Las estimaciones marginales/efectos de impacto del LPM se dividen por la estimación de la densidad de probabilidad **kernel** evaluada en el cuantíl de interés.
- ▶ Esto invierte localmente los efectos de probabilidad (incondicionales) de nuevo a sus efectos sobre el cuantíl (incondicional).
- ▶ Sin embargo, en lugar de estimar el LPM, sustituimos los dos valores de la RIF por los correspondientes resultados de la variable dependiente binaria (0 y 1) respectivamente?
- ▶ y luego se regresa la variable dicotómica resultante de la RIF sobre las variables explicativas usando OLS.
- ▶ **PREGUNTA:** ¿Cómo se obtiene la estimación de la densidad kernel $f_Y(q_\tau)$?





- ▶ Hemos establecido anteriormente que la RIF es una variable dicotómica que toma uno de dos valores:
- ▶ Si la variable aleatoria es menor o igual al cuantíl q_τ , entonces

$$q_\tau + \frac{\tau - 1}{f_Y(q_\tau)}$$

- ▶ Por lo tanto, en el percentil 10:

$$\begin{aligned} \text{RIF}_{0.1}(\text{below}) &= q_{0.1} + \frac{0.1 - 1}{f_Y(q_\tau)} \\ &= 3.009504 + \frac{0.1 - 1}{0.393879} \\ &= 0.7245 \end{aligned}$$



- ▶ Cuando la variable aleatoria está por encima del cuantíl q_τ , entonces tenemos:

$$q_\tau + \frac{\tau}{f_Y(q_\tau)}$$

- ▶ Por lo tanto, en el percentil 10:

$$\begin{aligned} \text{RIF}_{0.1}(\text{above}) &= q_{0.1} + \frac{0.1}{f_Y(q_\tau)} \\ &= 3.009504 + \frac{0.1}{0.393879} \\ &= 3.2634 \end{aligned}$$



```
*** compute RIF for the 10th, 25th, 50th, 75th and 90th quantiles
```

```
foreach qt of numlist 10 25 50 75 90 {  
  gen rif_`qt'=.  
}
```

```
*** for the female sample
```

```
pctile eval2=lnwage if male==0 , nq(100)  
kdensity lnwage if male==0, at(eval2) gen(eval_nw dens_nw) gau width(0.0981) nograph
```

```
foreach qt of numlist 10 25 50 75 90 {  
  local qc = `qt'/100  
  replace rif_`qt'=eval_nw[`qt'] + `qc'/dens_nw[`qt'] if lnwage>=eval_nw[`qt'] & male==0  
  replace rif_`qt'=eval_nw[`qt'] - (1-`qc')/dens_nw[`qt'] if lnwage<eval_nw[`qt'] & male==0  
}
```

Modelo de Regresión cuántilica incondicional



```
. centile lnwage if male==1, centile (10)
```

Variable	Obs	Percentile	Centile	— Binom. Interp. —	
				[95% Conf. Interval]	
lnwage	751	10	3.009504	2.929848	3.050997

```
. tab rif_10 if male==1
```

rif_10	Freq.	Percent	Cum.
.7245418	74	9.85	9.85
3.263389	677	90.15	100.00
Total	751	100.00	

```
. su rif_10 if male==1
```

Variable	Obs	Mean	Std. Dev.	Min	Max
rif_10	751	3.013223	.7571748	.7245418	3.263389

- ▶ Este es el valor del percentil 10 del logaritmo del salario para los hombres.
- ▶ Estos son los dos valores de RIF_{10} para la submuestra masculina:
 - ▶ 0.7245418 para los casos menores o iguales al valor del percentil 10.
 - ▶ 3.263389 para los casos mayores al valor del percentil 10.
- ▶ Esta variable se utiliza como variable dependiente en el modelo de regresión de cuantiles incondicionales para el percentil 10.
- ▶ La media muestral de RIF_{10} es (aproximadamente) el valor del percentil 10 del logaritmo del salario de los hombres.



- ▶ Estime los siguientes modelos de regresión incondicional por OLS para el percentil J para cada grupo de género:

$$\begin{aligned} \text{RIF}_{-J_i} = & \beta_{0,\tau} + \beta_{1,\tau} \text{educ}_i + \beta_{2,\tau} \text{exper}_i + \beta_{3,\tau} \text{expersq}_i \\ & + \beta_{4,\tau} \text{tenure}_i + \beta_{5,\tau} \text{married}_i + \beta_{6,\tau} \text{divorce}_i + \varepsilon_{i,t} \end{aligned}$$

- ▶ Donde:
 - ▶ τ es el valor del cuantíl (por ejemplo, $\tau = 0.1$) y ε_i es un término de error;
 - ▶ y donde $J = 10, 25, 50, 75$ y 90 (es decir, RIF_{10} , RIF_{25} , RIF_{50} , RIF_{75} y RIF_{90}).
- ▶ Luego, ¡implemente la descomposición de Oaxaca!

Cuadro: RIF-Oaxaca-Blinder desomposition

	10 th	25 th	50 th	75 th	90 th
Gap	-0.249*** (0.044)	-0.194*** (0.029)	-0.136*** (0.026)	-0.152*** (0.029)	-0.139*** (0.037)
Explicada	0.015 (0.028)	-0.012 (0.020)	-0.042* (0.018)	-0.011 (0.018)	0.026 (0.025)
No Explicada	-0.264*** (0.049)	-0.182*** (0.032)	-0.094*** (0.027)	-0.141*** (0.031)	-0.165*** (0.042)
Obs					

Source: DB4.

Elaboration: Author

***, **, * denote statistical significance at the 1 %, 5 % and 10 % levels respectively for zero.

Glass ceiling y Sticky floor





- La consultora **Marilyn Loden** , quien acuñó el termino **techo de cristal** en 1978 , es también la autora del libro Liderazgo femenino o ¿cómo triunfar en los negocios sin ser uno de los chicos?.

Glass ceiling y Sticky floor





- ▶ En 1991, la Comisión de **Techos de Vidrio (glass ceiling)** del Departamento de Trabajo de EE. UU. (1991-1996) definió el **techo de vidrio** como:



- ▶ En 1991, la Comisión de **Techos de Vidrio (glass ceiling)** del Departamento de Trabajo de EE. UU. (1991-1996) definió el **techo de vidrio** como:
- ▶ ... esas barreras artificiales basadas en prejuicios organizacionales o de actitud que impiden que las personas calificadas asciendan en su organización a puestos de nivel gerencial.



- ▶ En 1991, la Comisión de **Techos de Vidrio (glass ceiling)** del Departamento de Trabajo de EE. UU. (1991-1996) definió el **techo de vidrio** como:
- ▶ ... esas barreras artificiales basadas en prejuicios organizacionales o de actitud que impiden que las personas calificadas asciendan en su organización a puestos de nivel gerencial.
- ▶ El concepto de **techo de cristal** se convirtió en el objeto de un estudio de investigación sistemático desde finales de los años ochenta.



- ▶ En 1991, la Comisión de **Techos de Vidrio (glass ceiling)** del Departamento de Trabajo de EE. UU. (1991-1996) definió el **techo de vidrio** como:
- ▶ ... esas barreras artificiales basadas en prejuicios organizacionales o de actitud que impiden que las personas calificadas asciendan en su organización a puestos de nivel gerencial.
- ▶ El concepto de **techo de cristal** se convirtió en el objeto de un estudio de investigación sistemático desde finales de los años ochenta.
- ▶ Los sociólogos estuvieron a la vanguardia de las primeras investigaciones y (algunos) economistas se interesaron a fines de la década de 1990.



- ▶ En 1991, la Comisión de **Techos de Vidrio (glass ceiling)** del Departamento de Trabajo de EE. UU. (1991-1996) definió el **techo de vidrio** como:
- ▶ ... esas barreras artificiales basadas en prejuicios organizacionales o de actitud que impiden que las personas calificadas asciendan en su organización a puestos de nivel gerencial.
- ▶ El concepto de **techo de cristal** se convirtió en el objeto de un estudio de investigación sistemático desde finales de los años ochenta.
- ▶ Los sociólogos estuvieron a la vanguardia de las primeras investigaciones y (algunos) economistas se interesaron a fines de la década de 1990.
- ▶ El enfoque original de los economistas en esta área era la promoción, no el pago.



- ▶ En 1991, la Comisión de **Techos de Vidrio (glass ceiling)** del Departamento de Trabajo de EE. UU. (1991-1996) definió el **techo de vidrio** como:
- ▶ ... esas barreras artificiales basadas en prejuicios organizacionales o de actitud que impiden que las personas calificadas asciendan en su organización a puestos de nivel gerencial.
- ▶ El concepto de **techo de cristal** se convirtió en el objeto de un estudio de investigación sistemático desde finales de los años ochenta.
- ▶ Los sociólogos estuvieron a la vanguardia de las primeras investigaciones y (algunos) economistas se interesaron a fines de la década de 1990.
- ▶ El enfoque original de los economistas en esta área era la promoción, no el pago.
- ▶ A principios de la década de 2000, las regresiones cuantílicas se utilizaban de forma rutinaria en esta investigación para centrarse en la remuneración.

Glass ceiling y Sticky floor





- ▶ La socióloga Catherine Berheide, quien acuñó la frase **piso pegajoso** (sticky floor) en 1992




- ▶ La socióloga Catherine Berheide, quien acuñó la frase **piso pegajoso** (sticky floor) en 1992
- ▶ El **piso pegajoso** se refiere a los casos en los que las mujeres ocupan puestos de baja categoría, bajos salarios y de baja movilidad en el mercado laboral.



- ▶ La socióloga Catherine Berheide, quien acuñó la frase **piso pegajoso** (sticky floor) en 1992
- ▶ El **piso pegajoso** se refiere a los casos en los que las mujeres ocupan puestos de baja categoría, bajos salarios y de baja movilidad en el mercado laboral.
- ▶ Donde se dice:



- ▶ La socióloga Catherine Berheide, quien acuñó la frase **piso pegajoso** (sticky floor) en 1992
- ▶ El **piso pegajoso** se refiere a los casos en los que las mujeres ocupan puestos de baja categoría, bajos salarios y de baja movilidad en el mercado laboral.
- ▶ Donde se dice:
- ▶ ... la mayoría de las mujeres deberían tener la suerte de tener el techo de cristal como su problema ... muchas están atascadas en el piso pegajoso.



Cuadro: RIF-Oaxaca-Blinder desomposition

	10 th	25 th	50 th	75 th	90 th
Gap	-0.249*** (0.044)	-0.194*** (0.029)	-0.136*** (0.026)	-0.152*** (0.029)	-0.139*** (0.037)
Explicada	0.015 (0.028)	-0.012 (0.020)	-0.042* (0.018)	-0.011 (0.018)	0.026 (0.025)
No Explicada	-0.264*** (0.049)	-0.182*** (0.032)	-0.094*** (0.027)	-0.141*** (0.031)	-0.165*** (0.042)
Obs					

Source: DB4.

Elaboration: Author

***, **, * denote statistical significance at the 1%, 5% and 10% levels respectively for zero.